

Forecasting Otomasyon Pipeline: E-Ticaret Sistemleri İçin n8n ve Büyük Dil Modeli Tabanlı Talep Tahmini Otomasyonu

Hasan Safa Aytaş
Bilgisayar Mühendisliği
Kastamonu Üniversitesi
Kastamonu, Türkiye
hasansafaaytas@gmail.com
0009-0004-7530-3476

Özet— Bu çalışmada n8n otomasyon platformu ve Google Gemini (Büyük Dil Modeli) entegrasyonu ile eldeki ürün satış verileri kullanılarak gelecek hafta satış miktarı tahmin edilmektedir. Geliştirilen sistemde geçmiş tahminlerin doğruluk oranını Ortalama Mutlak Yüzde Hata (MAPE) metriği ile hesaplayan ve bu sonucu dil modeline sözel bir uyarı olarak sunan geri bildirim döngüsü yer almaktadır. Projede yapay zekanın kendi tahmin yönelimini düzeltmekte ve kritik stok seviyelerinde otonom olarak tedarik zinciri aksiyonlarını tetikleyerek kullanıcıyı e-mail yoluyla uyarmaktadır.

Anahtar Kelimeler—yapay zeka otomasyonu, e-ticaret, büyük dil modeli, talep tahmini, geri bildirim döngüsü, n8n, Gemini

I. GİRİŞ

Günümüz e-ticaret ekosisteminde kârlılığın temel anahtarı tedarik zincirinin doğru yönetilmesinden geçmektedir. Stok fazlası depolama maliyetlerini artırırken stok yetersizliği doğrudan ciro kaybına ve müşteri memnuniyetsizliğine yol açmaktadır. E-ticaret satış verilerinin barındırdığı resmi tatiller, hafta sonu yoğunlukları, ve dönemsel kampanyalar gibi doğrusal olmayan dalgalanmaların talep tahmini üzerindeki kritik rolü, M5 Accuracy Competition sonuçlarında [1] açıkça ortaya koyulmuştur. Ancak geleneksel istatistiksel zaman serisi yöntemleri bu tür semantik ve takvimsel bağlamları kavramakta ve ani yapısal kırılmaları modellemekte yetersiz kalmaktadır. Büyük Dil Modellerinin (LLM) örüntü tanıma yeteneklerinin sayısal verilere uygulanması Sıfır-Atışlı (Zero-Shot) tahminleme alanında yeni bir paradigma doğurmuştur. Dil modellerinin sayısal zaman serilerini metinsel belirteçler olarak okuyup başarılı tahminler üretebildiği [2] ve sayısal girdilerin doğrudan "cümleden-cümleye" [3] bir öğrenme yapısına dönüştürülebileceği bilimsel olarak gözlemlenmiştir. Buna karşın büyük dil modellerinin tek başına konumlandırılması modelin zaman içindeki tahmin yönelimini ve hata birikimini denetleyememektedir. Yapay zeka ajanlarının kendi kararlarını değerlendirebilmesi için literatürde önerilen Reflexion (sözel pekiştirmeli öğrenme) çerçevesi [4], modellerin geçmiş hatalarına ilişkin metinsel geri bildirimleri hafızada tutarak sonraki adımlarda karar süreçlerini iyileştirmesini ve

performansını otonom biçimde artırmasını savunmaktadır. Talep tahminlerinin başarı ölçümlerinde farklı ölçeklerdeki e-ticaret ürünleri arasında karşılaştırılabilirlik sağlaması nedeniyle Ortalama Mutlak Yüzde Hata (MAPE) metriği literatürde yaygın olarak kullanılan bir değerlendirme ölçütüdür [5]. Bu çalışmada literatürdeki bu teorik altyapılar temel alınarak low-code entegrasyon aracı n8n ve Google Gemini altyapısı üzerinde koşan otonom bir talep tahmini pipeline mimarisi önerilmektedir. Sistem her tahmin döngüsünde geçmiş veriler ile eski tahminleri kıyaslayarak MAPE hesaplamakta ve elde edilen başarı oranını dinamik olarak prompt içerisine enjekte etmektedir. Böylece model eksik (under-forecast) veya aşırı (over-forecast) tahmin eğilimlerini kendi kendine düzelterek kritik stok durumlarında tedarik zinciri aksiyonlarını (Gmail API) otonom olarak tetiklemektedir.

II. SİSTEM MİMARİSİ

A. Veri Entegrasyonu ve Hazırlık Katmanı

Sistem, n8n üzerindeki bir zamanlayıcı düğüm (Schedule Trigger) aracılığıyla periyodik olarak tetiklenmektedir. Akış başladığında veri kaynağı olan Google Sheets tablolarından iki farklı veri seti eşzamanlı olarak çekilir.

1) Günlük ham satış ve stok verileri.

2) Sistemin ürettiği geçmiş tahmin raporları.

Verilerdeki eksik (null) değerler, modellerin halüsinasyon görmesine veya hatalı örüntüler çıkarmasına neden olmaktadır. Bu sorunu aşmak için veri hattına özel bir JavaScript kod düğümü (Code Node) eklenmiş eksik sayısal girdiler "0", eksik metinsel girdiler ise "Bilinmeyen Ürün" olarak standardize edilerek veri temizliği otonom hale getirilmiştir.

B. Öz-Değerlendirme ve MAPE Hesaplama Katmanı

Bu katman sistemin geçmiş döngülerdeki hataların matematiksel olarak ölçüldüğü değerlendirme katmanıdır. E-ticaret ürünleri arasındaki hacimsel ölçek farklarını (örneğin günde 10 adet satan klavye ile 150 adet satan kulaklık)

normalize etmek için, Hyndman ve Koehler [5] tarafından tavsiye edilen Ortalama Mutlak Yüzde Hata (MAPE) metriği kullanılmıştır. Algoritma, her bir ürün için bir önceki haftanın tahmini (F_t) ile son 7 günün gerçekleşen fiili satış toplamını (A_t) aşağıdaki denklem yardımıyla karşılaştırır:

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right| \times 100 \quad (1)$$

Denklem (1)'den elde edilen sonuç doğrultusunda sistem tahminin "Aşırı" (Over-forecast) veya "Eksik" (Under-forecast) yönelimli olduğunu tespit eder ve bir durum özeti oluşturur.

C. LLM Çıkarımı ve Kapalı Devre Geri Bildirim Katmanı

Hesaplanan performans karnesi ve günlük veriler Google Gemini modeline iletilir. Modelin kullandığı istem (prompt) ile profesyonel bir e-ticaret veri analitiği yapay zekası olduğu talimatı verilir ve tahmin edilen değerler ile gerçek değerler arasındaki MAPE skorunu bir eleştiri olarak alır. Modelden e-ticaret kampanyaları ve tatiller gibi geleceğe dönük yapılandırılmamış olay sinyallerini geçmiş verilerle harmanlaması istenir. Bu olay akıl yürütme ve sayısal tahmin doğruluğunu artırır.

D. Raporlama Katmanı

LLM tarafından üretilen çıktılar JavaScript koduyla ayrıştırılır ve Google Sheets kullanılarak veri tabanına kaydedilir.

E. Otonom Aksiyon ve Uyarı Katmanı

JSON çıktısı (önümüzdeki 7 günün tahmini), mevcut stokla kıyaslanır ve "Kritik" ürünler için satın alma yöneticilerine otonom uyarılar (Gmail) iletilerek otonom zincir tamamlanır.

III. DENEYSEL UYGULAMA VE BULGULAR

Sistem performansını ve doğruluğunu incelemek amacıyla elektronik tüketici ürünleri kategorisinde yer alan üç farklı ürün grubuna (Akıllı Saat V2, Bluetooth Kulaklık Pro, Mekanik Klavye) ait 18 Mart - 17 Mayıs 2026 tarihleri arasındaki 60 günlük e-ticaret satış ve envanter verileri simüle edilmiştir. Her tahmin döngüsünde son 7 günlük tahmin verileri doğru şekilde izole ederek gerçekleşen satışlar ile model tahminlerini matematiksel olarak kıyaslamıştır.

Yapılan deneysel testler ve sistemin kararlı hale getirilmesinin ardından geri bildirim döngüsünün modele entegre edilmesiyle birlikte sistem genelinde elde edilen toplam ortalama tahmin hatası (MAPE) %9,6 olarak ölçülmüştür. Sonuçlar incelendiğinde şu bulgulara ulaşılmıştır:

- Mekanik Klavye: Doğrusal ve stabil satış grafiğine sahip bu kategoride hata payı %2'nin altına düşmüş modelin başarıyla tahminde bulunduğu gözlemlenmiştir.
- Bluetooth Kulaklık Pro ve Akıllı Saat V2: Anneler Günü gibi belirli dönemlerde ani talep dalgalanmaları gösteren bu dinamik kategorilerde modelin olası tahmin sapmaları sisteme aktarılan geçmiş dönem hata karnesi ve takvimsel bağlam parametreleri sayesinde otonom olarak dengelenmiştir.

IV. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada klasik makine öğrenmesi modellerini sıfırdan eğitmeye gerek kalmadan n8n ve büyük dil modelleri ile çalışan bir talep tahmini ve envanter yönetim sistemi geliştirilmiştir. Elde edilen %90.4'lık genel ortalama doğruluk değeri sıfır-atışlı zaman serisi tahmini yapan LLM tabanlı yaklaşımların yüksek bir doğrulukla tahmin ortaya koyduğunu göstermektedir. Önceki tahminleri gerçek verilerle karşılaştırılarak yapay zekanın kendi ürettiği hatalardan ders çıkarabilmesi sağlanmış ve açık döngülü sistemlerde yaşanan hata birikmesi probleminin önüne geçilmiştir.

Projenin geliştirilmesi ve test edilmesi sürecinde karşılaşılan en önemli kısıtlarından biri yapay zekanın yapılandırılmış JSON çıktısı üretirken zaman zaman küçük harf hataları yapabilmesidir. Bu problem sistem promptunun daha katı kurallarla sıkılaştırılması ile çözülmüştür.

Gelecekte bu projenin daha büyük kurumsal yapılara taşınabilmesi için şu geliştirme alanları öngörülmektedir:

- Ürün sayısı ve veri hacmi büyüdüğünde dil modelinin karakter (token) sınırına takılmaması için tüm verileri tek seferde göndermek yerine ürün bazlı toplu işleme döngülerinin kurgulanması.
- Google Sheets API'sinin kota limitlerine takılmamak ve veri güvenliğini artırmak için depo katmanının PostgreSQL veya Google BigQuery gibi ilişkisel veri ambarlarına (Data Warehouse) taşınması.

Sonuç olarak, low-code araçlar ve dil modelleriyle kurgulanan bu otonom mimari, tedarik zinciri süreçlerinde insan hatasını azaltmakta ve yüksek maliyetli veri bilimi yatırımlarına bütçe ayıramayan e-ticaret işletmeleri için operasyonları kolaylaştıran sürdürülebilir bir çözüm sunmaktadır.

KAYNAKLAR

- [1] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "The M5 Accuracy competition: Results, findings and conclusions," *International Journal of Forecasting*, 2021.
- [2] N. Gruver, M. Finzi, S. Qiu, and A. G. Wilson, "Large Language Models Are Zero-Shot Time Series Forecasters," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [3] Xue, H., & Salim, F. D. PromptCast: A New Prompt-Based Learning Paradigm for Time Series Forecasting. *IEEE Transactions on Knowledge and Data Engineering*, 2024.
- [4] N. Shinn, F. Cassano, E. Berman, A. Gopinath, K. R. Narasimhan, and S. Yao, "Reflexion: Language Agents with Verbal Reinforcement Learning," in *Proceedings of the Annual Conference on Neural Information Processing Systems (NeurIPS)*, 2023.
- [5] R. J. Hyndman and A. B. Koehler, "Another look at measures of forecast accuracy," *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006, doi: 10.1016/j.ijforecast.2006.03.001.
- [6] D. Reyes Fernández De Bulnes and P. Rosati, "ARIMA Forecasting with LLM-Powered Multi-Agent Coordination for Omnichannel Retail KPIs," in *Proc. 12th IEEE Int. Conf. Intelligent Computing and Information Systems (ICICIS)*, Cairo, Egypt, 2025, doi: 10.1109/ICICIS66182.2025.11313215abc.
- [7] C. Hu, Y. Shi, F. Huang, ve M. Jin, "EventCast: Hybrid Demand Forecasting in E-Commerce with LLM-Based Event Knowledge," *arXiv preprint arXiv:2602.07695*, 2026.